

Optimización – Proyecto Final

Estimación de desempeño individual en sistemas multiagente mediante optimización con restricciones y redes neuronales.

Emanuel Michel Naverrete Gomez

Kaleb Alejandro Aguilar Ávila

3 de julio de 2026

Resumen

En sistemas multiagente, estimar la contribución individual de cada agente a partir de resultados colectivos representa un problema inverso debido a que únicamente se observan métricas agregadas del sistema. En este trabajo se propone una metodología para estimar el desempeño individual de robots colaborativos utilizando datos históricos de la competencia FIRST Robotics Competition (FRC). El problema se formula como una optimización restringida con restricciones de no negatividad.

El problema de estimar contribuciones individuales admite múltiples soluciones factibles. Para reducir esta ambigüedad, la función de pérdida incorpora un término de regularización que favorece soluciones cercanas a una estimación previa y verosímil del desempeño individual. Se evaluaron dos enfoques para construir dichas estimaciones. El primero utiliza una aproximación estadística basada en la distribución uniforme del desempeño colaborativo entre los robots de una alianza, tomando como referencia el puntaje promedio global de cada robot. El segundo emplea una red neuronal con mecanismos de atención para estimar distribuciones de desempeño considerando las interacciones entre agentes. La optimización se resolvió mediante descenso de gradiente proyectado (PGD) y por L-BFGS-B.

Los modelos fueron evaluados utilizando datos del campeonato mundial, considerando 997 partidos con combinaciones de robots no observadas durante el entrenamiento. Los resultados muestran mejoras significativas respecto a enfoques basados únicamente en distribuciones promedio, reduciendo el error de predicción y aumentando la precisión en la predicción de resultados de partidos. En particular, la optimización con inicializaciones a partir de redes neuronales, tuvieron menor error medio y mayor precisión en la predicción de ganadores.

1. Objetivo General

Desarrollar una metodología de optimización restringida para estimar el desempeño individual de robots en sistemas multiagente colaborativos, utilizando datos históricos de la competencia FIRST Robotics Competition (FRC). La propuesta busca inferir contribuciones individuales a partir de resultados colectivos mediante funciones de costo robustas, restricciones de no negatividad y modelos neuronales auxiliares capaces de incorporar información contextual sobre las interacciones entre agentes.

2. Descripción del problema

Durante la temporada analizada de FIRST Robotics Competition (FRC) se disputaron aproximadamente 30,090 partidos distribuidos en 206 torneos regionales y un campeonato mundial. En cada partido participan seis robots organizados en dos equipos de tres integrantes. Cada torneo regional reúne aproximadamente entre 40 y 50 robots, los cuales participan en alrededor de 75 partidos clasificatorios donde las combinaciones de equipos se organizan por sorteo aleatorio. Esta dinámica genera un sistema multiagente con configuraciones variables de colaboración entre robots, formando un conjunto de datos adecuado para el análisis estadístico y la inferencia de desempeño individual. En total, son 3658 robots a caracterizar. La variación constante en las configuraciones de equipos nos motivó a asumir que las contribuciones individuales de los robots pueden modelarse de forma independiente entre partidos.

El juego consiste en encestar pelotas dentro de una estructura. El partido tiene una duración total de 2 minutos 30 segundos. Los primeros quince segundos corresponden a una fase autónoma donde los robots operan sin intervención humana, mientras que los dos minutos y quince segundos restantes corresponden a una fase teleoperada controlada por operadores humanos. Dependiendo del nivel competitivo del evento, un equipo puede anotar entre 100 y 700 pelotas por partido, generando secuencias de anotación altamente dinámicas y difíciles de analizar manualmente.

Aunque el resultado colectivo de cada equipo es observable mediante sensores instalados en las estructuras de anotación, no existe una medición directa de la contribución individual de cada robot durante el partido. Debido a la velocidad con la que ocurren las anotaciones y a la interacción simultánea entre múltiples agentes, estimar manualmente el aporte individual resulta inviable. Esto convierte la estimación de desempeño individual en un problema inverso donde únicamente se observan resultados agregados del sistema, admitiendo múltiples soluciones factibles y requiriendo métodos de optimización capaces de incorporar restricciones físicas y conocimiento previo.

3. Metodología y procedimiento

Como primera aproximación, el problema se modela como una estimación lineal de contribuciones individuales a partir de resultados colectivos observados. Para ello, se construye una matriz A que representa la participación de cada robot en los partidos históricos, un vector X correspondiente al desempeño individual desconocido de cada agente y un vector Y que contiene los puntajes observados en los partidos. El objetivo consiste en encontrar una estimación de X que minimice el error entre las contribuciones agregadas del modelo y los resultados reales observados, formulando el problema como una optimización cuadrática restringida:

$$\min_{X \geq 0} \|AX - Y\|^2$$

La restricción de no negatividad se impone debido a que las contribuciones negativas de puntos no tienen interpretación física dentro del contexto del problema. Además, el análisis se realiza de manera independiente para las fases autónoma y teleoperada del juego, permitiendo modelar por separado el desempeño de los

robots bajo condiciones de operación completamente autónomas y bajo interacción humana.

Sin embargo, debido a la naturaleza colectiva del problema, múltiples configuraciones de desempeño individual pueden producir resultados agregados similares. En la práctica, esto genera soluciones inestables y dificulta la convergencia hacia estimaciones físicamente razonables utilizando únicamente una función de costo basada en error cuadrático. Para reducir esta ambigüedad, se incorpora un término de regularización centrado en una estimación previa μ_0 del desempeño esperado de cada robot. Se evaluaron dos estrategias para construir dicho prior: una aproximación estadística basada en distribuciones promedio y una aproximación basada en redes neuronales con mecanismos de atención.

3.1. Análisis de la Restricción

Tenemos nuestra función de pérdida

$$\min_{X \geq 0} L(X) = \sum_{i=1}^M \rho_q(y_i - a_i^T X) + \frac{1}{2}(X - \mu_0)^T \text{diag}(1/\tau_0^2)(X - \mu_0)$$

donde $X \in \mathbb{R}^n$ y la restricción $X \geq 0$ significa que $x_j \geq 0$, $j \in \{1, \dots, n\}$, ρ_q es la función de pérdida por cuantiles.

Por lo tanto nuestro Lagrangiano, con el suavizado de la pérdida por cuantiles queda de la forma

$$\begin{aligned} e_i &= y_i - a_i^T X \\ X^* &= (A^T A)^{-1} A^T Y \\ \mathcal{L}(X, \lambda) &= \sum_i^M \rho_q \left(\sqrt{e_i^2 + \beta^2} - \beta \right) + \frac{1}{2}(X - \mu_0)^T D(X - \mu_0) - \underbrace{\lambda^T X}_{\text{restricción}} \end{aligned}$$

Por condición de estacionariedad de KKT tenemos que

$$\nabla_X \mathcal{L}(X, \lambda) = 0$$

Y calculando el gradiente de nuestro Lagrangiano por partes

$$\begin{aligned} \nabla_X \left(\sum_i \phi(e_i) \right) &= - \sum_i \omega_i \frac{e_i}{\sqrt{e_i^2 + \beta^2}} a_i \\ \nabla_X \left(\frac{1}{2}(X - \mu_0)^T D(X - \mu_0) \right) &= D(X - \mu_0) \\ \nabla_X (\lambda^T X) &= \lambda \end{aligned}$$

$$\nabla_X \mathcal{L}(X, \lambda) = - \sum_i \omega_i \frac{e_i}{\sqrt{e_i^2 + \beta^2}} a_i + D(X - \mu_0) - \lambda = 0$$

Y obtenemos que

$$- \sum_i \omega_i \frac{e_i}{\sqrt{e_i^2 + \beta^2}} a_i + D(X - \mu_0) = \lambda$$

$$\boxed{\lambda = \nabla L}$$

Este resultado lo que nos está diciendo es que la ponderación del multiplicador es completamente dependiente del gradiente de la función de pérdida. Analizando componente a componente tenemos

$$\frac{\partial L}{\partial x_j} = \lambda_j$$

$$\lambda_j x_j = 0$$

Lo cual produce dos casos, para impedir que la solución óptima se salga de la región factible.

- $x_j > 0$
Implica que $\lambda_j = 0$, que $\frac{\partial L}{\partial x_j} = 0$.
- $x_j = 0$
Implica que $\lambda_j > 0$, que $\frac{\partial L}{\partial x_j} > 0$.

Los multiplicadores de Lagrange compensan las componentes del gradiente que apuntan fuera de la región factible, de manera que el gradiente del lagrangiano sea cero en el punto crítico restringido.

3.2. Optimización por descenso de gradiente proyectado

Se propone al función de pérdida:

$$\min_{X \geq 0} L(X) = \sum_{i=1}^M \rho_q(y_i - a_i^T X) + \frac{1}{2}(X - \mu_0)^T \text{diag}(1/\tau_0^2)(X - \mu_0)$$

- A : Matriz de matches históricos con todos los regionales.
- X : Vector de valores esperados individuales por robot.
- Y : Vector de resultados histórico.

Donde ρ_q es una función de costo asimétrica de tipo Quantile Loss (Pinball Loss)

$$\rho_q(y, \hat{y}) = \begin{cases} q(y - \hat{y}) & \text{si } y \geq \hat{y} \\ (1 - q)(\hat{y} - y) & \text{si } y < \hat{y} \end{cases} \quad q \in (0, 1) \quad (1)$$

$$\rho_q(y, \hat{y}) = \max(q \cdot (y - \hat{y}), (q - 1) \cdot (y - \hat{y}))$$

La función está diseñada para ser asimétrica, y al igual que la función de valor absoluto, no es diferenciable en cero.

- Si $q > 0.5$: Se castiga más subestimar (cuando el valor real es mayor que la predicción). Esto es útil si el costo de quedarse corto es muy alto.
- Si $q < 0.5$: Se castiga más sobreestimar (cuando el valor real es menor que la predicción).
- Si $q = 0.5$: La pérdida se vuelve simétrica y equivale a la Desviación Media Absoluta (MAE).

Como no es diferenciable en cero, se utiliza una modificación para suavizar la función

$$L_q(e) = \sum_i \omega_q(e_i) \left(\sqrt{e_i^2 + \beta^2} - \beta \right)$$

Donde

$$\omega_q(e) = \begin{cases} q & \text{si } e \geq 0 \\ 1 - q & \text{si } e < 0 \end{cases}$$

Y tiene como gradiente

$$\frac{\partial L}{\partial \hat{y}_i} = -\omega_q(e_i) \frac{e_i}{\sqrt{e_i^2 + \beta^2}}$$

3.3. Gradiente de la función de pérdida

Tenemos la siguiente función de pérdida

$$L(X) = \underbrace{\sum_{i=1}^M \rho_q(y_i - a_i^T X)}_{L_{data}} + \underbrace{1/2 \cdot (X - \mu_0)^T \text{diag}(1/\tau_0^2)(X - \mu_0)}_{L_{reg}}$$

Donde

$$\nabla_X L_{data} = \sum_i \left(\omega_q(e_i) \frac{e_i}{\sqrt{e_i^2 + \beta^2}} \right) (-a_i)$$

$$\nabla_X L_{reg} = \text{diag}(1/\tau_0^2)(X - \mu_0)$$

Por lo tanto el gradiente de nuestra función de pérdida es

$$\nabla_X L(X) = - \sum_i^M \omega_i \frac{e_i}{\sqrt{e_i^2 + \beta^2}} a_i + \text{diag}(1/\tau_0^2)(X - \mu_0)$$

Algorithm 1 Projected Gradient Descent

Require: $A, y, q, \beta, \eta_0, \rho, c, \varepsilon, K_{\text{máx}}, \mu_0, \tau_0^2, X^{(0)}$

```

1:  $X \leftarrow X^{(0)}$ 
2:  $e_0 \leftarrow y_i - a_i^T X$ 
3: for  $k = 0, \dots, K_{\text{máx}} - 1$  do
4:    $e_i \leftarrow y_i - a_i^T X$ 
5:    $w_i \leftarrow q$  if  $e_i \geq 0$ , else  $1 - q$ 
6:    $s_i \leftarrow w_i e_i / \sqrt{e_i^2 + \beta^2}$ 
7:    $g \leftarrow - \sum_{i=1}^M s_i a_i + \text{diag}(1/\tau_0^2)(X - \mu_0)$ 
8:   if  $\|e_0 - e_i\|_2 < \varepsilon$  then
9:     break
10:  end if
11:   $\eta \leftarrow \eta_0$ 
12:  while true do
13:     $X_t \leftarrow \text{máx}(X - \eta g, 0)$ 
14:    if  $L(X_t) \leq L(X) - c\eta \|g\|_2^2$  then
15:      break
16:    end if
17:     $\eta \leftarrow \rho\eta$ 
18:  end while
19:   $X \leftarrow X_t$ 
20: end for
21: return  $X$ 
```

3.4. Estimación previa (μ_0) basada en promedio colaborativo

Como primer estrategia, se construye un prior estadístico μ_0 utilizando el desempeño promedio observado de cada robot a lo largo de la temporada. Para ello, el puntaje colectivo obtenido en cada partido se distribuye uniformemente entre los integrantes del equipo correspondiente, permitiendo calcular una estimación promedio de contribución individual para cada agente. Esta aproximación sirve como una referencia inicial simple y consistente con la hipótesis de contribuciones aproximadamente independientes entre robots.

$$\mu_{0,j} = \frac{1}{N_j} \sum_{i \in \mathcal{P}_j} \frac{y_i}{3}$$

donde $\mathcal{P}_j$ representa el conjunto de partidos en los que participó el robot j , N_j es el número total de partidos jugados por dicho robot y y_i corresponde al puntaje total obtenido por su equipo en el partido i .

3.5. Estimación previa (μ_0) mediante red neuronal con capa de atención

Como segunda estrategia, se propone una red neuronal que estima μ_0 considerando las interacciones contextuales entre robots dentro de un mismo equipo. El prior estadístico de la sección anterior asigna $\mu_{0,j}$ únicamente en función del historial individual de cada robot, ignorando que su contribución efectiva puede variar según con quién y dónde compite. Capturar esta dependencia contextual produce un prior más informativo, reduciendo la ambigüedad del problema.

Representación de agentes. Cada robot r_i se caracteriza inicialmente mediante un vector de entrada $\mathbf{x}_i^{(0)} \in \mathbb{R}^p$ que concatena tres fuentes de información disponibles antes del entrenamiento:

$$\mathbf{x}_i^{(0)} = \left[\mathbf{x}_i^{\text{sparse}} \mid \mathbf{x}_i^{\text{regional}} \mid \mathbf{x}_i^{\text{stat}} \right] \quad (2)$$

El componente $\mathbf{x}_i^{\text{sparse}} \in \{0, 1\}^{N_{\text{robots}}}$ es una codificación one-hot que identifica al robot. El componente $\mathbf{x}_i^{\text{regional}} \in \mathbb{R}^{N_{\text{reg}}}$ codifica el desempeño del robot en cada torneo regional: si el robot no participó en el torneo t , la entrada correspondiente es 0; si participó, se asigna su puntaje promedio normalizado al intervalo $[-1, 1]$, donde -1 corresponde al mínimo y $+1$ al máximo observado en ese torneo. Finalmente, $\mathbf{x}_i^{\text{stat}} \in \mathbb{R}^s$ contiene estadísticas agregadas del robot: promedio de puntos anotados, número de partidos jugados y el prior estadístico $\mu_{0,j}$ de la sección anterior. Esta representación inicial es de alta dimensión y dispersa; en particular, $\mathbf{x}_i^{\text{sparse}}$ tiene dimensión $N_{\text{robots}} = 3658$, lo que hace inviable utilizarla directamente como entrada a capas densas. Por ello, se aprende una proyección compacta mediante una tabla de embeddings $E \in \mathbb{R}^{N_{\text{robots}} \times d}$:

$$\mathbf{e}_i = E[r_i] \quad (3)$$

Estos vectores densos $\mathbf{e}_i \in \mathbb{R}^d$ son parámetros aprendidos durante el entrenamiento que dan una codificación latente de cada robot. Intuitivamente, robots con estilos de juego similares deberían ocupar regiones cercanas en $\mathbb{R}^d$, permitiendo que el mecanismo de atención identifique complementariedades dentro de una alianza.

Construcción del target: distribución suave sobre bins. La variable objetivo de la red no es el puntaje escalar y_m , sino una distribución de probabilidad construida artificialmente sobre un espacio discreto de $B = 64$ bins. El rango de puntajes normalizados $[0, 1]$ se discretiza uniformemente; dado el puntaje normalizado $\tilde{y}_m = y_m / y_{\text{máx}}$, el índice de bin correspondiente es:

$$b_m = \text{mín}(\lfloor \tilde{y}_m \cdot B \rfloor, B - 1) \quad (4)$$

A partir de b_m se construye un vector de pesos $\mathbf{t}_m \in \Delta^{B-1}$ normalizando directamente una campana de ancho $\sigma = 3$ bins:

$$t_m^{(k)} = \frac{\exp\left(-\frac{(k - b_m)^2}{2\sigma^2}\right)}{\sum_{j=0}^{B-1} \exp\left(-\frac{(j - b_m)^2}{2\sigma^2}\right)}, \quad k = 0, \dots, B-1 \quad (5)$$

De esta manera, $\mathbf{t}_m \in \Delta^{B-1}$ asigna probabilidad a los bins vecinos de b_m , introduciendo una incertidumbre artificial de $\pm\sigma$ bins alrededor del valor observado. En lugar de exigir que el modelo reproduzca exactamente b_m , el target admite predicciones cercanas sin penalizarlas bruscamente. Las B distribuciones posibles $\{\mathbf{t}_k\}_{k=0}^{B-1}$ se precomputan una sola vez antes del entrenamiento.




Figura 1: Diagrama de construcción del Soft target.

Mecanismo de atención intra-alianza. Dado un equipo de $n = 3$ robots con embeddings $\{\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3\}$, se proyectan a espacios de consulta, clave y valor mediante matrices entrenables $W_Q, W_K, W_V \in \mathbb{R}^{d \times d_k}$:

$$\mathbf{q}_i = W_Q \mathbf{e}_i, \quad \mathbf{k}_i = W_K \mathbf{e}_i, \quad \mathbf{v}_i = W_V \mathbf{e}_i \quad (6)$$

Los pesos de atención del robot i hacia el robot j se calculan mediante producto punto escalado:

$$\alpha_{ij} = \frac{\exp(\mathbf{q}_i^\top \mathbf{k}_j / \sqrt{d_k})}{\sum_{m=1}^n \exp(\mathbf{q}_i^\top \mathbf{k}_m / \sqrt{d_k})} \quad (7)$$

donde $\alpha_{ij} \geq 0$ y $\sum_j \alpha_{ij} = 1$. El factor $1/\sqrt{d_k}$ estabiliza los gradientes cuando d_k es grande. La representación contextualizada de cada robot es entonces:

$$\mathbf{h}_i = \sum_{j=1}^n \alpha_{ij} \mathbf{v}_j \quad (8)$$

De este modo, $\mathbf{h}_i$ depende de la configuración completa de la alianza, no solo del robot i : el mismo robot produce representaciones distintas según sus compañeros. Esto es precisamente lo que el prior promedio no puede capturar.

Función de pérdida de la red. La red produce logits $\mathbf{z}_m \in \mathbb{R}^B$ a partir de los cuales se obtiene la distribución predicha mediante:

$$\hat{\mathbf{p}}_m = \text{softmax}(\mathbf{z}_m) \quad (9)$$

Inicialmente se entrenó minimizando únicamente la exactitud de clasificación sobre el bin b_m , equivalente a entropía cruzada con target one-hot. Sin embargo, este enfoque producía un comportamiento indeseable: el modelo asignaba distribuciones predichas más dispersas a los robots de alto desempeño que a los de bajo desempeño, introduciendo artificialmente mayor incertidumbre precisamente donde el sistema debería ser más

confiable. Para corregir esto, se incorporó un término de regularización entrópica que penaliza explícitamente las distribuciones predichas excesivamente concentradas.

$$\mathcal{L} = \underbrace{-\sum_k t_m^{(k)} \log \hat{p}_m^{(k)}}_{\text{entropía cruzada}} - \lambda_H \underbrace{\left(-\sum_k \hat{p}_m^{(k)} \log \hat{p}_m^{(k)}\right)}_{H(\hat{\mathbf{p}}_m)} \quad (10)$$

con $\lambda_H = 0.25$. El término $H(\hat{\mathbf{p}}_m)$ es la entropía de Shannon de la distribución predicha; al restarlo con signo negativo en la función de pérdida, maximizarlo equivale a penalizar la concentración excesiva. El resultado es que el modelo aprende a ser igualmente incierto ante robots de cualquier nivel de desempeño.

El puntaje esperado se recupera como la esperanza de la distribución predicha sobre los bins, reescalada al rango original:

$$\hat{y}_m = y_{\text{máx}} \cdot \frac{\sum_{k=0}^{B-1} k \hat{p}_m^{(k)}}{B-1} \quad (11)$$

Uso como prior (μ_0). Una vez entrenado el modelo, para cada robot j se recopilan todas sus apariciones en los partidos regionales y se promedia su estimación individual:

$$\mu_{0,j} = \frac{1}{|\mathcal{P}_j|} \sum_{m \in \mathcal{P}_j} \hat{x}_j^{(m)} \quad (12)$$

$$\mu_{0,j} = \frac{1}{3} T(x_j, x_j, x_j)$$

$$T(x_i, x_j, x_k) = \hat{y}$$

donde $\hat{x}_j^{(m)}$ es la contribución estimada del robot j en el partido m según el modelo de atención, y $\mathcal{P}_j$ es el conjunto de partidos en que participó durante la fase regional. Este vector μ_0 reemplaza al prior estadístico en la función de costo del PGD y L-BFGS-B, inicializando el problema de optimización en una región del espacio factible que ya incorpora dependencias contextuales.

3.6. Arquitectura de la red y entrenamiento

El diagrama de la Figura 2 ilustra el flujo completo del modelo para una triada de tres robot y su target. Cada vector de entrada $\mathbf{x}_i^{(0)}$ pasa de forma independiente por su propio bloque de embedding, produciendo una representación densa $\mathbf{e}_i \in \mathbb{R}^{512}$. Las tres representaciones convergen en la capa de atención, donde cada robot construye una representación contextualizada $\mathbf{h}_i$ ponderando las contribuciones de sus compañeros de alianza. Finalmente, el regresor mapea cada $\mathbf{h}_i$ a logits $\mathbf{z} \in \mathbb{R}^{64}$, cuya distribución softmax se compara contra el soft target $\mathbf{t}_m$ durante el entrenamiento.




Figura 2: Diagrama general de la Red

Ambos modelos (fase autónoma y fase teleoperada) comparten la misma arquitectura y protocolo de entrenamiento. El optimizador utilizado es SGD con momento $\beta = 0.9$, tasa de aprendizaje inicial $\eta_0 = 3 \times 10^{-4}$ y regularización L2 con $\lambda = 10^{-3}$ (weight decay). La tasa de aprendizaje se ajusta dinámicamente mediante un scheduler `ReduceLROnPlateau` con paciencia de 5 épocas y factor de reducción 0.5. El entrenamiento se realizó por $N = 30$ épocas con tamaño de batch $B = 256$.

Para incorporar la estructura temporal de los datos, las muestras se ponderan de acuerdo a su posición cronológica en la temporada: los partidos más recientes reciben mayor peso durante el entrenamiento, sesgando el modelo hacia el desempeño tardío de los robots. La partición train/val/test respeta el orden temporal, reservando los partidos del campeonato mundial como conjunto de prueba con combinaciones de robots no observadas durante el entrenamiento. Los principales hiperparámetros del modelo se resumen a continuación:

Hiperparámetro	Valor	Descripción
B	64	Número de bins
σ	3 bins	Suavidad del soft target
λ_H	0.25	Peso del término de entropía
d	512	Dimensión de embeddings
Épocas	30	Por modelo (auto y tele)
Batch size	256	Muestras por época
η_0	3×10^{-4}	Tasa de aprendizaje inicial
Weight decay	10^{-3}	Regularización L2

Cuadro 1: Hiperparámetros de arquitectura y entrenamiento.

4. Análisis de Resultados

Los modelos fueron evaluados sobre 997 partidos del campeonato mundial, correspondientes a combinaciones de robots no observadas durante el entrenamiento.

Precisión en predicción de ganador. El indicador más directo de utilidad práctica es la exactitud en la predicción del ganador del partido. Todos los modelos con prior informativo superan al baseline por un margen considerable: PGD+Red alcanza 0.8020, el resultado más alto, seguido de cerca por LBFGS+Red con 0.8000. La diferencia entre ambos optimizadores con el mismo prior es de apenas 0.002, lo que sugiere que la calidad del prior μ_0 es el factor dominante sobre la elección del método de optimización. El prior

estadístico uniforme (Avg/3) produce resultados intermedios, con una caída de aproximadamente 1.2 puntos porcentuales.

Error de predicción de margen. En términos de RMSE, PGD+Red y LBFGS+Red son prácticamente equivalentes (93.32 vs 93.81 pts), ambos representando una reducción del 47.8 % respecto al baseline (178.99 pts). El prior Avg/3 produce errores notablemente mayores (103 pts), lo que confirma que la red neuronal captura información contextual que el promedio uniforme no puede representar. El MAE de margen es similar entre todos los modelos con prior informativo (95-96 pts), lo que indica que los errores grandes están distribuidos de forma parecida independientemente del optimizador.

Calibración y cobertura. La cobertura (fracción de partidos cuyo margen real cae dentro del intervalo de predicción) es superior para LBFGS+Red (0.7292) frente a PGD+Red (0.7182). Esta diferencia, aunque moderada, sugiere que L-BFGS-B produce estimaciones con intervalos de incertidumbre mejor calibrados, posiblemente debido a su convergencia más suave hacia el mínimo de la función de costo regularizada.

Sesgo en la predicción de scores absolutos. El Cuadro 3 revela un patrón importante: el optimizador con μ_0 de la red sobreestiman el score real en apenas +5.87 pts (PGD) y +9.45 pts (LBFGS), mientras que los modelos con μ_0 Avg/3 sobreestiman en +40 pts. El baseline, en contraste, subestima drásticamente (−134.12 pts), consecuencia de que la distribución uniforme concentra las estimaciones alrededor del promedio global. Como consecuencia subestima a los más buenos y sobreestima a los más malos. La desviación estándar de las predicciones de la red (77–80 pts) es notablemente menor que la del score real (99.83 pts), lo que indica que el modelo no reproduce la cola superior de la distribución de scores, por lo tanto, los partidos de más alta puntuación siguen siendo difíciles de predecir.

Convergencia de L-BFGS-B. Una diferencia considerable entre optimizadores es el comportamiento de convergencia. LBFGS+Red converge en 1495 iteraciones para la fase autónoma y 2706 para la teleoperada, mientras que LBFGS+Avg/3 requiere 3617 y 5000 iteraciones respectivamente, sin converger en la fase teleoperada. Esto es consistente con la hipótesis de que un prior informativo inicializa el problema en una región del espacio factible más cercana al óptimo, reduciendo el trabajo del optimizador. El μ_0 de la red no solo mejora la calidad de la solución sino que acelera la convergencia.

Modelo	Accuracy	RMSE (pts)	NRMSE	MAE margen (pts)	Cobertura	Iters (auto/tele)
PGD + Red	0.8020	93.32	0.6451	96.00	0.7182	5000*/5000*
PGD + Avg/3	0.7899	102.92	0.7116	95.45	0.6981	5000*/5000*
LBFGS + Red	0.8000	93.81	0.6485	95.76	0.7292	1495 / 2706
LBFGS + Avg/3	0.7889	104.19	0.7203	95.80	0.6981	3617 / 5000*
Baseline (Avg/3)	0.7678	178.99	1.2374	134.76	N/A	—

Cuadro 2: Evaluación mundial: 997 partidos en 8 divisiones. *No convergió (límite de iteraciones alcanzado).

Predictor	Score medio (pts)	σ (pts)	Δ vs. real (pts)
Score real	416.40	99.83	—
PGD + Red	422.27	77.00	+ 5.87
PGD + Avg/3	456.77	85.96	+40.37
LBFGS + Red	425.85	79.96	+ 9.45
LBFGS + Avg/3	459.08	87.77	+42.69
Baseline	282.28	28.91	−134.12

Cuadro 3: Estadísticas de predicción de score agregado por alianza — fase mundial.

Distribuciones predichas por la red. Las Figuras 3 y 4 muestran las distribuciones $\hat{\mathbf{p}}_m$ predichas sobre los 64 bins para cada robot. Sin ordenamiento las distribuciones aparecen dispersas; al ordenar por valor esperado se observa un gradiente diagonal claro, con robots de alto desempeño concentrando masa en bins altos y viceversa. La anchura de cada distribución refleja la incertidumbre del modelo: ningún robot colapsa a un bin único, lo que produce un prior μ_0 con varianza que el optimizador puede explotar.




Figura 3: Distribuciones predichas para cada robot.




Figura 4: Distribuciones predichas para cada robot ordenando por valor esperado (el bin con más probabilidad)

Comparación entre predictores por robot. (PGD) valores esperados individuales normalizados $[0, 1]$ para los 3658 robots, comparando PGD+Red, PGD+Avg/3, μ_0 de la red y μ_0 por Avg/3 en ambas fases




Figura 5: EPA esperado por robot en fase autónoma




Figura 6: EPA ordenado por robot en fase autónoma




Figura 7: EPA esperado por robot en fase teleoperada




Figura 8: EPA ordenada por robot en fase teleoperada

Comparación entre predictores por robot. Las Figuras 7–10 muestran los valores esperados individuales normalizados $[0, 1]$ para los 3658 robots, comparando LBFGS+Red, LBFGS+Avg/3, μ_0 de la red y μ_0 por Avg/3 en ambas fases. Ordenando por índice global (Figuras 9 y 11), se observa que todos los modelos producen distribuciones de color heterogéneas, sin un patrón claro de ranking. Al ordenar por el EPA estimado por LBFGS+Red (Figuras 10 y 12), se observa un gradiente suave de azul a rojo en la columna LBFGS+Red, confirmando consistencia interna del modelo. En contraste, las columnas de Avg/3 muestran mayor ruido y discontinuidades, evidenciando que el prior uniforme no distingue eficazmente entre robots de distinto nivel. Notablemente, μ_0 de la red ya exhibe un gradiente parcialmente ordenado antes de la optimización, lo que justifica su uso como punto de inicialización: la red aprende un ranking latente que el optimizador refina.




Figura 9: EPA calculado con LBFGSB fase autónoma




Figura 10: EPA ordenado obtenido por LBFGSB fase autónoma




Figura 11: EPA calculado con LBFGSB fase teleoperada




Figura 12: EPA ordenado obtenido por LBFGSB fase teleoperada

Embeddings aprendidos. Las Figuras 13 y 14 muestran los embeddings aprendidos para los 3658 robots ordenados por valor esperado. Se observa un gradiente vertical suave en ambas fases: robots de alto desempeño tienden a activar con mayor intensidad ciertas dimensiones, aunque el patrón es distribuido y no localizado en dimensiones específicas. La fase teleoperada presenta activaciones ligeramente más intensas que la autónoma.




Figura 13: Embeddings de fase autónoma.




Figura 14: Embeddings de fase teleoperada.

5. Conclusiones

- Se obtuvo un mejor resultado que el baseline en los 4 modelos.
- El impacto más significativo no provino de la red, sino del optimizador: la proyección del gradiente redistribuyó las contribuciones individuales hacia configuraciones consistentes con los resultados observados, reduciendo el sesgo de sobreestimación en cada experimento, de +40 a +6 pts y de +43 a +9 puntos aproximadamente.
- Utilizar la red como semilla y regulación nos ayudó a obtener una distribución más suave entre los robots
- Ambos optimizadores son efectivos para predecir la alianza ganadora, superando al baseline en más de 3 puntos porcentuales (0.80 vs 0.77), con una diferencia marginal entre PGD y L-BFGS-B que no justifica preferir uno sobre el otro en términos de precisión. Pero si en tiempo de cómputo, el L-BFGS-B es mejor.

- Usar esta metodología en competencias con reglas más complejas. Consideramos que eso implicaría que el promedio estadístico sea menos descriptivo y por ende la red tenga que aprender más información.

Limitaciones y Mejoras

- En un futuro, se puede utilizar también una ponderación cronológica para la etapa del optimizador, para considerar la mejora de los equipos a lo largo del tiempo
- Analizar posibles modificaciones al vector característico de entrada de la red.
- Probar otras funciones de pérdida más suaves y robustas para el error de los resultados predichos.
- Analizar diferentes arquitecturas de la red, para posibles mejoras en puntaje esperado.

6. Referencias

- J. Nocedal and S. J. Wright, Numerical Optimization, Springer Series in Operation Research, 2000
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017, 12 junio). Attention is all you need. arXiv.org. <https://arxiv.org/abs/1706.03762>
- Cowles, M. K. (2013). Applied Bayesian Statistics: With R and OpenBUGS Examples. <https://doi.org/10.1007/978-1-4614-5696-4>

7. Anexos: Ejemplos de Robots




Figura 15: Robot 254




Figura 16: Robot 4414




Figura 17: Robot 6017




Figura 18: Robot 3478




Figura 19: Robot 7421




Figura 20: Robot 6170